

모델 서빙 및 AIOps 구성 실습 서브노트 (Day1 ~ Day3 누적)

- 작성: SKALA 6반 6조 · P195 이민기
- 실습 기간: 2026-09-30 (Day1) ~ 2026-10-02 (Day3, 조별 발표), 최종 정리 2026-10-03
- 실습 위치: project/ (HAIC 스펙레톤), 조별 과제는 project_solar/ (해아림)
- 환경: macOS Apple Silicon, Python 3.11, fastapi 0.141, tensorflow 2.21, mlflow 3.16. Day2~3 전체 루프는 클라우드 리눅스 환경에서도 한 번 더 돌려서 숫자가 같은지 확인했다.

0. 전체 결과 요약

Day	항목	결과
1	baseline RMSE	\$2.87 (Mac, 100 epoch 15초) / \$2.41 (리눅스). 둘 다 게이트 \$4.00 안
1	/predict 정상·비정상	20거래일 → 200, predicted_close 192.03 / 197개·close=0 → 422
1	Lazy vs Eager (3회 평균)	Lazy 시작 0.27초·첫 요청 3.11초 / Eager 시작 2.82초·첫 요청 0.18초
2	train_and_register.py	[GATE PASSED] rmse=2.03 -> HAIC_Predictor v1 promoted to Production
2	MODEL_SOURCE=mlflow	/predict 응답 model_version0 production-v1
2	Docker	빌드 안에서 시드·학습·등록까지 끝나고 8000 포트에서 같은 응답
3	정상 배치	drift_check = {'status': 'ok'}
3	드리프트 배치	retrain_triggered, promoted: True, rmse: 1.47
3	aiops.log	WARN → INFO → OK 세 줄, 16초 만에 v2 승격
3	재학습 전후 /predict	같은 입력에 166.26 (v1) → 167.14 (v2)

실습가이드 9번 완료 기준 8개는 전부 체크했다. 마지막 항목(재배포 후 새 버전이 응답하는가)은 처음에 안 됐고 고치고 나서 됐다. 4-7에 적었다.

1. 이해관계자 가치 (Pain Point)

수업 첫 시간에 교수님이 하신 말 중에 제일 남은 게 "3개월 박수"였다. 데이터 사이언티스트가 공장에 들어가서 모델 잘 만들어 놓으면 딱 3개월 박수받고, 3개월 지나면 안 맞는다고 전화 오고, 가면 혼난다는 얘기. 처음엔 웃었는데 Day3에 드리프트 배치 넣어보고 나니까 그게 그냥 농담이 아니었다. 서버는 멀쩡히 200을 내는데 값만 틀린다. 교수님 표현대로 "AI는 에러 없이 틀린다".

1-1. 모델이 노트북에만 있을 때 (Day1)

이해관계자	서빙이 없으면
사용자(투자 분석가)	예측값이 필요할 때마다 데이터 과학자한테 부탁해야 한다.
운영자	모델이 떠 있는지 알 방법이 없다. 사용자가 먼저 발견한다.
모델 개발자	학습 때랑 다른 형태의 입력이 들어와도 막을 데가 없다.
경영진	학습에 돈 썼는데 서비스에 안 붙어 있으니 얻는 게 없다.

직접 겪은 걸로 적으면, Day1에 Lazy로 서버를 띄웠더니 모델 파일이 없는데도 /health 가 status: ok 였다. 운영자가 그것만 보고 있었으면 장애를 몰랐을 것이다. 서버가 살아 있는 것과 예측할 준비가 된 것은 다른 얘기다. 이 차이가 Day1에서 제일 크게 와닿았다.

1-2. 모델을 바꿔 배포했는데 뭐가 바뀌었는지 모를 때 (Day2)

Day2에서 train_and_register.py 를 돌렸더니 콘솔에 HAIC_Predictor v1 이 찍혔다. 그런데 클라우드에서 다시 돌릴 때는 이전 세션 기록이 남아 있어서 v3부터 시작했다. 내가 지금 서빙 중인 게 몇 번째 버전인지 기록이 없으면 본인도 헷갈린다는 걸 직접 겪었다.

이해관계자	버전 관리와 게이트가 없으면
모델 개발자	어떤 실험이 더 나았는지 기억에 의존한다.
운영자	방금 배포한 모델이 전보다 나은지 모르는 채 트래픽을 받는다.
경영진	성능 나쁜 모델이 실수로 나가는 걸 막을 장치가 없다.

1-3. 모델이 조용히 나빠질 때 (Day3)

Day1, Day2는 뭔가 안 되면 에러가 났다. Day3는 다르다. 드리프트 배치를 넣었을 때 서버 로그 어디에도 에러가 없었다. drift_check 의 RMSE 값만 커졌다. 그리고 재학습이 돌았다는 로그와 서빙에 반영된 것은 또 다른 일이라는 걸 4-7의 버그로 알았다. [OK] production promoted 가 찍혔는데 /predict 는 그대로였다. 로그만 보고 됐다고 판단했으면 아무것도 안 바뀐 서비스를 계속 운영하고 있었을 것이다.

이해관계자	모니터링과 드리프트 감지가 없으면
사용자	모르는 사이에 틀린 예측으로 의사결정한다.
운영자	항의가 쌓이기 전까지 모른다.
모델 개발자	언제부터 나빠졌는지 나중에 로그를 뒤져서 역추적해야 한다.

조별 과제에서는 이걸 태양광 발전소로 바꿨다. 전력중개사업자는 매일 아침 10시 전에 다음 날 24시간 발전량을 제출해야 하고, 오차가 크면 그날 정산을 못 받는다. 여기서 Pain Point가 하나 더 생겼다. 오차가 커졌을 때 그게 날씨 탓인지 설비 고장인지 모델이 낡아서인지 모른다는 것. 이건 HAIC에는 없던 문제였다.

2. 이를 해결하기 위한 AI 솔루션

교수님이 "와이어링"이라는 말을 계속 쓰셨다. 머신러닝, 딥러닝, 백엔드, 프론트, 랭체인 다 따로 배웠는데 그걸 선으로 이어서 운영되게 만드는 게 AIOps라고. 3일 실습이 딱 그 와이어링이었다.

Day	기술	역할	내가 확인한 것
1	FastAPI 라우터, Pydantic 스키마	모델을 API로 감싸고, 학습 때랑 같은 모양의 입력만 통과시킨다	19개·close≤0은 모델에 달기 전에 422
1	/health, Lazy/Eager	서버 상태와 모델 로딩 여부를 밖에 알리고, 로딩 비용을 언제 낼지 고른다	3-1 측정표
2	MLflow Tracking	학습마다 파라미터·RMSE·모델 파일을 기록한다	log_param, log_metric("rmse")
2	Model Registry, 배포 게이트	RMSE ≤ \$4를 통과한 버전만 Production으로 올린다	[GATE PASSED] rmse=2.03 -> v1
2	_load_from_mlflow()	서버가 버전 번호가 아니라 Production 단계를 바라보게 한다	model_version0 production-v1
2	Dockerfile, docker-compose	의존성과 학습·등록 과정을 이미지에 고정한다	컨테이너에서 같은 RMSE, 같은 응답
3	drift_detector.py	최근 21건 RMSE를 \$4와 비교한다	정상 ok, 드리프트 재학습
3	retrain_trigger.py	warm start fine-tuning, 게이트 재검증, 승격, 캐시 비우기	WARN, INFO, OK 로그
3	simulate_drift.py	정상 변동성과 3배 변동성을 재현해 루프를 검증한다	send_batch 구현

수업에서 "FastAPI는 모델 서빙용으로만 쓴다"는 것도 처음 알았다. 파이썬은 컴파일이 안 돼서 컨테이너를 열면 코드가 다 보이고, 패키지 버전 종속성이 6개월마다 꼬여서 엔터프라이즈 백엔드는 스프링 부트로 하고 추론 엔진만 FastAPI로 한다고. 지금까지 FastAPI로 뭐든 만들 수 있다고만 생각했는데 역할이 정해져 있다는 게 새로웠다.

3. 아키텍처 구성도




그림 1. 업로드부터 재배포까지 전체 흐름 (HAIC 실습 기준). 실선 상자는 코드, 점선 상자는 파일과 저장소, 회색 상자는 판정, 빨간 선은 재학습 뒤 재배포 경로.

scaler.pkl은 Day1에 한 번 fit한 뒤 Day3까지 그대로 쓴다. train_and_register.py도 fine_tune도 HAICScaler.load() 로 읽기만 한다.

3-1. 핵심 질문 1) Lazy vs Eager (Day1)

같은 20거래일 입력으로 모드마다 서버를 새로 띄워 3번씩 잤다. 시작 시간은 프로세스 실행부터 /health 200 까지, 요청 시간은 /predict 를 연속 2번.

항목	Lazy (평균)	Eager (평균)
서버 시작	0.27 s	2.82 s
첫 /predict	3.11 s	0.18 s
두 번째 /predict	0.024 s	0.018 s
시작 직후 /health	model_loaded: false	model_loaded: true

원시값 (3회)

mode	run	시작	첫 요청	두 번째
lazy	1	0.308	4.149	0.024
lazy	2	0.259	2.856	0.022
lazy	3	0.253	2.333	0.025
eager	1	2.267	0.172	0.018
eager	2	3.095	0.180	0.018
eager	3	3.104	0.185	0.017

해석. 모델 로드 비용 2~3초는 없어지지 않는다. 누가 내느냐가 다를 뿐이다. Lazy는 첫 사용자가 내고 Eager는 서버가 뜰 때 낸다. 시작과 첫 요청을 합치면 Lazy 3.38초, Eager 3.00초로 비슷하다.

Eager인데도 첫 요청이 0.18초로 두 번째 0.018초보다 10배 느린 게 이상했다. 모델 파일은 이미 읽었는데 왜 느리지 않았는데, TensorFlow가 첫 `predict()` 호출 때 연산 그래프를 준비하는 것 같다. 기동 시 더미 입력으로 한 번 예측해 두면 없어질 거라고 본다.

실제 서비스라면. 교수님이 "정답은 없고 상황에 따라 다르다"고 하셨는데 측정해 보니까 기준이 생겼다. 컨테이너나 쿠버네티스처럼 헬스체크 통과해야 트래픽 받는 환경이면 Eager다. 모델 파일이 깨져 있으면 뜨는 단계에서 바로 실패하니까 잘못된 버전이 트래픽 받기 전에 걸러진다. Day2 Dockerfile이 `LOADING_MODE=eager` 인 이유도 그거다. 개발 중에 `--reload` 로 자주 재시작하거나 어떤 모델을 쓸지 나중에 정해지는 경우는 Lazy다. 조별 과제에서도 컨테이너는 Eager, 로컬 개발은 Lazy로 갈랐다.

3-2. 핵심 질문 2) 학습 시점과 서빙 시점의 일치 (Day1)

왜 20거래일 시퀀스인가. 모델이 `Input(shape=(SEQ_LEN, 2))` 로 학습됐기 때문이다. `PredictRequest` 가 `data/features.SEQ_LEN` 을 import해서 `min_length=max_length=20` 으로 강제한다. 숫자를 스키마에 따로 적어 두면 나중에 입력 길이를 바꿀 때 한쪽만 바뀌어서 어긋난다. 19개를 보내면 모델까지 안 가고 422에서 끝난다.

왜 `scaler.pkl`은 Day1에 한 번만 fit하는가. 가중치가 Day1 min-max 기준(증가 105.61~195.17)으로 변환된 숫자에 맞춰 학습돼 있다. 중간에 다시 fit하면 같은 \$190이 다른 숫자로 들어가서 가중치랑 안 맞는다. `fine_tune` 도 의미를 잃는다. 빈칸 5가 `HAICScaler.load(SCALER_PATH)` 인 이유다. 교수님이 "에러 없이 결과만 들어지는 조용한 실패"라고 하신 자리가 바로 여기서이다. 다시 fit해도 에러는 안 난다.

3-3. 핵심 질문 3) 배포 게이트 (Day2)

게이트가 없다면. `_register_if_gate_passed()` 는 `score <= RMSE_GATE` 일 때만 Production으로 올린다. 이 한 줄이 없으면 학습 끝난 모든 버전이 Production이다. 잘 된 모델과 나쁜 모델을 못 가린다.

통과 못한 버전은. MLflow run으로 기록만 남고 Registry Production으로 안 올라간다. 서버는 `models:/HAIC_Predictor/Production` 만 보니까 탈락한 버전은 서버 입장에서 없는 것과 같다. 기존 Production이 계속 서빙된다.

운영자에게 주는 가치. 배포하는 사람과 배포해도 되는지 판단하는 기준을 분리한다. 내 v1은 2.03으로 통과했는데 만약 \$4를 넘겼으면 콘솔에 `[GATE FAILED]` 만 찍히고 서비스는 그대로였을 것이다. 실패가 서비스 중단이 아니라 "아무 일도 안 일어남"으로 처리된다는 점이 좋았다.

3-4. 핵심 질문 4) 드리프트 판정 기준 (Day3)

윈도우와 임계값을 바꾸면. 윈도우를 5건처럼 짧게 잡으면 며칠 우연히 어긋나도 드리프트로 잡는다(오탐). 100건처럼 길게 잡으면 진짜 드리프트가 시작돼도 평균이 기준을 넘기까지 오래 걸린다(미탐). 임계값도 낮추면 오탐, 높이면 미탐. 21건은 한 달 거래일이라서 잡은 절충점이다.

실제 결과.

- 정상 배치 (변동성 1.2%): `{'status': 'ok'}`
- 드리프트 배치 (변동성 3배): `{'status': 'retrain_triggered', 'promoted': True, 'rmse': 1.47}`

여기서 한참 헷갈렸다. 응답의 `rmse: 1.47` 을 보고 "1.47인데 왜 드리프트지?" 했다. 코드를 다시 보니 이 값은 드리프트 판정에 쓴 RMSE가 아니라 재학습 직후 게이트 재검증에 쓴 RMSE였다. 판정용 RMSE(`compute_rmse()`로 최근 21건 계산해서 \$4 넘는 값)는 응답에 안 들어간다. 감지 오차와 재학습 평가 오차가 다른 값이라는 걸 숫자만 보고 넘어갈 뻔했다.

조별 과제에서는 임계값을 고정값으로 안 두고 검증 오차의 1.25배로 유도했다. 고정 8%를 썼더니 모델 평상시 오차가 8.3%라 매일 드리프트가 났기 때문이다. HAIC는 \$4 고정이라 이 문제가 안 보였는데 실제 데이터 넣으니 바로 나왔다.

3-5. 핵심 질문 5) 재학습 방식 (Day3)

scratch가 아니라 fine-tuning인 이유. 빈칸 10을 채우면서 직접 골라야 했다. 최근 21거래일에 창문 20일을 더한 41행으로 파라미터 1.6만 개짜리 LSTM을 처음부터 학습하면 샘플이 부족해서 불안정하다. 3년치로 학습된 Production 가중치에서 10 epoch만 이어서 배운다. 학습률도 $1e-4$ 로 $base(1e-3)$ 보다 낮게 뒀서 기존에 배운 걸 크게 안 흔든다.

재학습 모델이 게이트를 못 넘으면. `fine_tune`도 Day2와 같은 `_register_if_gate_passed()`를 탄다. 떨어지면 기존 Production이 그대로 남고 서비스는 안 멈춘다. 빈칸 11이 "promoted일 때만 OK 로그"인 이유다. 재학습을 시도했다는 것과 서비스가 바뀌었다는 것은 다르다. 4-7 버그로 더 확실히 알았다.

4. 트러블 슈팅

오류 메시지, 원인, 해결, 전후 순서로 적었다.

Day1

4-1. 모델 없이 /predict → 500

- 오류: `ValueError: File not found: filepath=serving_app/models/haic_v1.keras`
- 원인: Lazy라 서버는 모델 없이 뒀고, 첫 요청 때 로드하려다 파일이 없어 실패.
- 해결: 대시보드에서 CSV 업로드 후 `python scripts/train_baseline_v1.py`.
- 결과: `500 → 200 {"predicted_close": 192.03, "model_version": "v1-local"}`.
- 배운 점: `/health`는 프로세스가 살아 있는 것만 알려주고 예측 준비가 됐는지는 안 알려준다. 운영에서는 `model_loaded`까지 봐야 한다.

4-2. /predict → 422 too_short, greater_than

- 오류: `List should have at least 20 items after validation, not 19 / Input should be greater than 0, loc [body, sequence, 19, close]`.
- 원인: 시퀀스 19개, close=0. 스키마 위반.
- 해결: 오류가 아니라 스키마가 의도대로 동작한 것. loc으로 위치 찾아 수정.
- 배운 점: 교수님이 "규격을 안 잡으면 에러가 오염돼서 전파되고 어디서 터졌는지 모른다"고 하셨는데, 422는 핸들러가 실행되기 전에 끊어 주니까 원인이 바로 보인다. 500은 서버 탓, 422는 클라이언트 탓.

4-3. 포트 8000 vs 8077

- 증상: README 예시는 `--port 8077`, 실습가이드와 `simulate_drift.py`의 API_URL은 8000.
- 원인: 문서 간 포트 불일치. 교수님도 2일차에 "8000으로 드린 게 하나 있는데 8077로 바꿔야 한다"고 안내.
- 해결: 로컬은 8000으로 통일해서 실행. 컨테이너는 가이드대로 8000.
- 배운 점: README, Dockerfile, 스크립트 상수가 같은 포트를 가정하는지 먼저 확인. 조별 과제에서는 아예 환경변수 PORT로 빼고 8010 하나로 맞췄다.

4-4. 가상환경 이름과 활성화 경로 불일치 (fastapi_practice)

- 증상: README가 `python3.11 -m venv fastapi && source .venv/bin/activate`.
- 원인: 만든 이름(fastapi)과 활성화하는 경로(.venv)가 다름.
- 해결: `python3.11 -m venv .venv && source .venv/bin/activate`.

Day2

4-5. transition_model_version_stage FutureWarning

- 현상: `FutureWarning: transition_model_version_stage is deprecated since 2.9.0`.
- 원인: MLflow 3.x는 Stage 대신 alias(@champion) 방식을 권장. 실습 코드는 이전 API.
- 처리: 에러가 아니라 실습은 그대로 진행. 조별 과제에서는 alias로 바꿨다. `models:/Haearim_Hourly@champion`으로 로드하고 승격은 alias 이동.

4-6. 클라우드에서 돌렸더니 v3부터 시작

- 현상: `Registered model 'HAIC_Predictor' already exists... Created version '3'`.
- 원인: 이전 세션의 mlruns가 남아 있었다.
- 배운 점: Registry는 같은 이름으로 등록할 때마다 번호가 누적된다. 지금 서빙 중인 게 몇 번인지 항상 확인해야 하는 정보가 됐다. 그래서 /predict 응답에 `production-v1`처럼 번호를 넣었다(4-7 참고).

Day3

4-7. [OK] promoted 로그는 찍혔는데 /predict 응답이 그대로

- 현상: 드리프트 배치 전송 후 aiops.log에 `[OK] new_rmse=1.47 - production promoted: HAIC_Predictor v2`까지 찍혔다. 그런데 같은 입력으로 /predict를 다시 호출하니 재학습 전과 같은 값이 나왔다.

- 원인: `model_loader.get_model()` 은 `_model_cache` 가 None일 때만 다시 읽는다. 서버가 처음 뜰 때 v1을 캐시에 올려 두면 이후 Registry가 v2로 바뀌어도 서버는 모른다. 캐시를 비우는 코드가 어디에도 없었다. 실습가이드 부록 1의 6번이 딱 이 증상이었다.
- 해결: `retrain_trigger.py` 의 빈칸 11 안, `result["promoted"]` 가 True일 때 `model_loader.invalidate_cache()` 를 호출하도록 추가. `model_loader.py` 에 `invalidate_cache()` (캐시를 None으로)를 만들었다. 응답에 `production-v2` 처럼 버전 번호가 나오게 `_production_version_label()` 도 추가했다.
- 결과: 재학습 전 `{"predicted_close":166.26,"model_version":"production-v1"}` → 재학습 후 `{"predicted_close":167.14,"model_version":"production-v2"}`. 서버 재시작 없이 바뀌었다.
- 배운 점: 3일 중 제일 크게 배운 부분이다. 로그에 성공이 찍힌 것과 사용자에게 나가는 응답이 바뀐 것은 다르다. 교수님이 "재학습이 실행됐다고와 새 모델이 배포됐다는 같은 뜻일까요"라고 빈칸 11 주석에 써 두셨는데, 그 질문이 캐시 얘기까지 이어지는 줄은 겪고 나서야 알았다. 운영 중인 서비스에서 이런 건 가장 늦게 발견되는 종류의 장애일 것 같다.

4-8. 응답의 rmse 1.47이 판정 RMSE인 줄 알았음

- 현상: 3-4에 적은 대로. 1.47은 재학습 후 게이트 재검증 값.
- 배운 점: 감지용 오차와 평가용 오차를 응답에서 구분해서 내보내야 한다. 조별 과제에서는 `window_error` (판정)와 `new_error` (재학습 후)를 따로 돌려주게 했다.

4-9. 조별 과제에서 겪은 것: pip이 다른 파이썬에 설치됨

- 오류: `.venv/bin/python3: No module named uvicorn`.
- 원인: zsh에 `python3` 가 홈브루 파이썬으로 alias 돼 있어서 터미널의 `pip install` 은 홈브루에 깔리고, 스크립트는 `.venv` 를 써서 안에 아무것도 없었다.
- 해결: `.venv/bin/python -m pip install -r requirements.txt` 로 경로 직접 지정. 급할 땐 `PYTHON=/opt/homebrew/.../python3.11` 로 스크립트에 알려줬다.
- 배운 점: 프롬프트에 `(.venv)` 가 보여도 실제 그 파이썬을 쓰고 있다는 보장이 없다. `which python3` 를 먼저 보는 습관.

4-10. 조별 과제에서 겪은 것: 동봉 모델이 클론에 없음

- 오류: 팀원이 클론 후 `quick_start` 실행 시 `solarcast_v2.keras` 가 없습니다.
- 원인: `.gitignore` 에 `*.keras` 가 들어 있어서 zip에는 있는데 GitHub에는 안 올라갔다.
- 해결: 두 파일만 ! 예외로 풀어서 커밋.

5. 레퍼런스


5-1. 강의 키워드 정리

수업 중에 메모한 것을 키워드로 정리했다. 교수님이 여러 번 반복하신 말 위주다.


키워드	정리
데이터는 업무의 결과	업무는 계속 조금씩 바뀌니까 데이터도 바뀌고, 그래서 한 번 학습한 모델은 시간이 지나면 안 맞는다. 운영이 필요한 이유.
3개월 박수	모델 잘 만들고 3개월 지나면 전화 온다. 지속적으로 성능이 유지되게 운영하는 게 MLOps, 파이프라인까지 같이 보는 게 AIOps.
와이어링	머신러닝, 백엔드, 프론트, 랭체인 다 따로 배운 걸 선으로 연결해서 운영으로 완성하는 것.
FastAPI는 추론 서버로만	파이썬은 컴파일이 안 돼 코드가 노출되고 패키지 종속성이 자주 꼬인다. 엔터프라이즈 백엔드는 스프링 부트.
운영이 걸리는 순간	로컬에서 잘 돌아가는 것과 상용은 전혀 다르다. 지연시간, 가용성, 동시 사용자. 베이스라인을 정해 두고 넘으면 스케일아웃.
Swagger는 계약서	요청하면 이렇게 응답한다는 계약. 프론트와 백엔드가 이 계약으로 와이어링한다. 상용 배포 땐 /docs를 숨긴다.
Pydantic 스키마	규격을 안 잡으면 에러가 오염돼 전파되고 어디서 터졌는지 모른다. 모델에 달기 전에 422로 끊는다.
라우터 등록 순서	StaticFiles는 라우터를 다 등록한 뒤 마지막에 mount. 먼저 오면 /predict를 정적 파일이 가로챈다.
Lazy / Eager	로딩 비용을 첫 요청 때 낼지 기동 때 낼지. 모델이 나중에 정해지면 Lazy, 바로 써야 하면 Eager. 상황에 따라 다르다.
로깅	문제 생기면 흔적이 남아야 추적한다. 컨테이너에서 특히. aiops.log의 WARN, INFO, OK 세 줄이 재학습 이력이다.
MLflow를 왜 쓰나	학습할 때마다 생기는 가중치, 파라미터, 이력을 공유하고 관리할 레파지토리가 있어야 AIOps가 돈다. 직접 만들어도 되지만 있는 걸 쓴다.
게이트 \$4	업무 판단이다. 6달러, 8달러로 바뀌도 된다. 통과 못하면 기존 Production 유지.
스케일러	학습 때 기준으로 가중치가 맞춰져 있으니 다시 fit하면 같은 값이 다른 숫자로 들어간다.
조용한 실패	에러 없이 결과만 미세하게 틀어지는 것. 현장 가기 전엔 모른다. 빈칸이 그 자리에 있다.
컨테이너 100%	실제 배포는 컨테이너 기반. 로컬 띄우는 건 공부할 때만.
AI는 거울	맥락 없이 물으면 엉뚱한 답. 해본 사람이어야 제대로 시킬 수 있고 결과를 검증할 수 있다. AI한테 맡길 경계를 긋는 게 우리 역할.
Agentic AI	지연시간, 에러, 처리량을 사람이 계속 볼 수 없으니 에이전트가 감시하고 대응한다. 드리프트 감지 뒤 LLM으로 보고서 생성, RAG로 원인 검색까지 붙이면 예측형과 생성형이 결합된다.
포트폴리오	코드 공유로 실력이 인정되는 게 아니다. 기획서, 돌아가는 스냅샷, 서브노트가 포트폴리오다.

5-2. Day1 필수 증빙

① /docs (Swagger)



② Lazy 기동 직후 /health: 서버는 ok, 모델은 미로드



③ 모델 없이 /predict → 500

POST /predict Predict

Parameters Cancel Reset

No parameters

Request body required application/json

Edit Value | Schema

```

{
  "volume": 601047
},
{
  "close": 192.22,
  "volume": 620839
},
{
  "close": 194.79,
  "volume": 844426
},
{
  "close": 194.11,
  "volume": 609151
},
{
  "close": 195.17,
  "volume": 562936
}
}

```

Execute Clear

Responses

Request URL
`http://localhost:8000/predict`

Server response

Code	Details
500 Undocumented	Error: Internal Server Error Response body Internal Server Error Download Response headers <pre> content-length: 21 content-type: text/plain; charset=utf-8 date: Wed, 30 Sep 2020 06:37:17 GMT server: uvicorn </pre>

ValueError: File not found: filepath=serving_app/models/haic_v1.keras. Please ensure the file is an accessible `.keras` zip file.

④ CSV 업로드 → /data/status

HAIC 데이터 업로드

data/uploads/ 는 여기서 업로드한 CSV만 쌓이는 곳입니다. 학습(train_and_register.py 등)은 항상 가장 최근에 올라온 파일을 사용합니다. data/sample_haic_prices.csv 를 예시로 올려보세요 (컬럼: Date, Close, Volume · 최소 41행).

파일 선택 sample_haic_prices.csv

업로드

• 업로드 완료: haic_1790750254.csv (756행)

GET /data/status Status

Parameters
Cancel

No parameters

Execute Clear

Responses

Request URL
http://localhost:8000/data/status

Server response

Code Details

200

Response body

```

{
  "exists": true,
  "filename": "haic_1790750254.csv",
  "rows": 756,
  "start_date": "2026-01-02",
  "end_date": "2028-11-24",
  "min_close": 105.61,
  "max_close": 195.17
}

```

Download

Response headers

```

content-length: 147
content-type: application/json
date: Wed, 30 Sep 2026 06:37:35 GMT
server: uvicorn

```

⑤ train_baseline_v1.py

```

zsh — project — python scripts/train_baseline_v1.py

$ python scripts/train_baseline_v1.py
scaler fit on 756행 -> serving_app/models/scaler.pkl
baseline v1 RMSE = 2.41 (배포 게이트: $4.00)
saved -> serving_app/models/haic_v1.keras

```

```

$ python scripts/train_baseline_v1.py
scaler fit on 756행 -> serving_app/models/scaler.pkl
baseline v1 RMSE = 2.87 (배포 게이트: $4.00)
saved -> serving_app/models/haic_v1.keras
real 15.43

```

⑥ /predict Try it out → 200

POST /predict Predict

Parameters Cancel Reset

No parameters

Request body ^{required} application/json

Edit Value Schema

```

{
  "volume": 601047
},
{
  "close": 192.22,
  "volume": 620839
},
{
  "close": 194.79,
  "volume": 844426
},
{
  "close": 194.11,
  "volume": 609151
},
{
  "close": 195.17,
  "volume": 562936
}
}

```

Execute Clear

Responses

Request URL

http://localhost:8000/predict

Server response

Code Details

200

Response body

```

{
  "predicted_close": 192.03,
  "model_version": "v1-local"
}

```

Response headers

```

content-length: 53
content-type: application/json
date: Wed, 30 Sep 2026 06:38:08 GMT
server: uvicorn

```

입력 2028-10-27 ~ 2028-11-23 (20거래일) → 예측 \$192.03. 실제 다음 거래일 증가 \$192.71, 오차 \$0.68.

⑦ 422 검증 오류

POST /predict Predict

Parameters Cancel Reset

No parameters

Request body ^{required} application/json

Edit Value Schema

```

{
  "volume": 805788
},
{
  "close": 191.38,
  "volume": 601047
},
{
  "close": 192.22,
  "volume": 620839
},
{
  "close": 194.79,
  "volume": 844426
},
{
  "close": 194.11,
  "volume": 609151
}
}

```

Execute Clear

Responses

Request URL

http://localhost:8000/predict

Server response

Code Details

422 Error: Unprocessable Entity

Response body

```

{
  "detail": [
    {
      "type": "too_short",
      "loc": [
        "body",
        "sequence"
      ],
      "msg": "List should have at least 20 items after validation, not 19",
      "input": [
        {
          "close": 187.28,
          "volume": 669544
        },
        {
          "close": 187.78,
          "volume": 838432
        },
        {
          "close": 187.34,
          "volume": 1820983
        },
        {
          "close": 187.01,
          "volume": 643274
        }
      ]
    }
  ]
}


```

Response headers

```

content-length: 830
content-type: application/json
date: Wed, 30 Sep 2026 06:38:10 GMT
server: uvicorn

```



⑧ /health의 Lazy / Eager 차이

Lazy 첫 요청 이후	Eager 기동 직후
GET /health Health Parameters No parameters Execute Clear Responses Request URL http://localhost:8080/health Server response Code Details 200 Response body <pre> { "status": "ok", "model_loaded": true, "loading_mode": "lazy" } </pre> Response headers <pre> content-length: 57 content-type: application/json date: Wed, 28 Sep 2022 06:38:11 GMT server: uvicorn </pre>	GET /health Health Parameters No parameters Execute Clear Responses Request URL http://localhost:8081/health Server response Code Details 200 Response body <pre> { "status": "ok", "model_loaded": true, "loading_mode": "eager" } </pre> Response headers <pre> content-length: 58 content-type: application/json date: Wed, 28 Sep 2022 06:38:56 GMT server: uvicorn </pre>

⑨ Lazy vs Eager 측정표: 3-1 참조. 서버 콘솔:

```
zsh — project — uvicorn 서버 콘솔 (lazy x3 · eager x3)

$ LOADING_MODE=lazy uvicorn serving_app.main:app --host 0.0.0.0 --port 8000 # run 1
[lazy] 모델은 첫 /predict 요청이 들어올 때 로드됩니다.
[lazy] model loaded in 4.010s on first request
$ LOADING_MODE=lazy uvicorn serving_app.main:app --host 0.0.0.0 --port 8000 # run 2
[lazy] 모델은 첫 /predict 요청이 들어올 때 로드됩니다.
[lazy] model loaded in 2.740s on first request
$ LOADING_MODE=lazy uvicorn serving_app.main:app --host 0.0.0.0 --port 8000 # run 3
[lazy] 모델은 첫 /predict 요청이 들어올 때 로드됩니다.
[lazy] model loaded in 2.208s on first request
$ LOADING_MODE=eager uvicorn serving_app.main:app --host 0.0.0.0 --port 8000 # run 1
[eager] model loaded in 2.087s at startup
$ LOADING_MODE=eager uvicorn serving_app.main:app --host 0.0.0.0 --port 8000 # run 2
[eager] model loaded in 2.712s at startup
$ LOADING_MODE=eager uvicorn serving_app.main:app --host 0.0.0.0 --port 8000 # run 3
[eager] model loaded in 2.756s at startup
```

```
[lazy] model loaded in 4.010s on first request
[lazy] model loaded in 2.740s on first request
[lazy] model loaded in 2.208s on first request
[eager] model loaded in 2.087s at startup
[eager] model loaded in 2.712s at startup
[eager] model loaded in 2.756s at startup
```

5-3. Day2 필수 증빙

① train_and_register.py 실행 로그

```
zsh — project — python serving_app/train_and_register.py

$ python serving_app/train_and_register.py
2026/10/01 02:53:25 INFO mlflow.store.db.utils: Creating initial MLflow database tables...
2026/10/01 02:53:25 INFO mlflow.store.db.utils: Updating database tables
Successfully registered model 'HAIC_Predictor'.
2026/10/01 02:54:33 WARNING mlflow.tracking._model_registry.fluent: Run with id acf96183e116471695062d5fbc215f92 has no artifacts at artifact path 'model', registering model based on models:/m-68e1f02e33f440a192b42f4746c889e1 instead
Created version '1' of model 'HAIC_Predictor'.
[GATE PASSED] rmse=2.03 -> HAIC_Predictor v1 promoted to Production
```

```
Successfully registered model 'HAIC_Predictor'.
Created version '1' of model 'HAIC_Predictor'.
[GATE PASSED] rmse=2.03 -> HAIC_Predictor v1 promoted to Production
```

MLflow에는 `log_param`(epochs, seed 등)과 `log_metric`("rmse", 2.03) 이 run에 기록됐다. 백엔드는 `sqlite(mlflow.db)`.

② _load_from_mlflow() 구현 (빈칸 5 포함)

```
def _load_from_mlflow() -> LoadedModel:
    import mlflow.tensorflow
    keras_model = mlflow.tensorflow.load_model(MLFLOW_MODEL_URI) # models:/HAIC_Predictor/Production
    scaler = HAICScaler.load(SCALER_PATH) # [빈칸 5] 다시 fit하지 않는다
    return LoadedModel(keras_model=keras_model, scaler=scaler, version=_production_version_label())
```

③ MODEL_SOURCE=mlflow 기동 후 /predict

```
{"predicted_close":166.26,"model_version":"production-v1"}
```

v1-local 이 아니라 production-v1 로 나오니까 MLflow에서 읽은 것이 맞다.

④ Docker docker compose -f serving_app/docker-compose.yml up --build. 이미지 빌드 시점에 cp sample → data/uploads → train_baseline_v1.py → train_and_register.py 가 돌아서 [GATE PASSED] 까지 끝나고 컨테이너가 뜬다. ENV LOADING_MODE=eager 라 /health 가 처음부터 model_loaded: true. 8000 포트에서 /docs, /predict 가 로컬과 같은 응답을 냈다.

Dockerfile에서 눈에 들어온 것은 COPY requirements.txt 뒤에 pip install 이 먼저 오고 그 다음에 소스를 COPY 하는 순서다. 소스만 바뀌면 의존성 레이어는 캐시에서 쓴다는 걸 두 번째 빌드가 빨라지는 걸로 확인했다.

⑤ Day2를 ML 라이프사이클에 매핑

데이터 수집	학습	검증	배포	모니터링
Day1 CSV 업로드	MLflow Tracking	RMSE 게이트	Registry 승격, Docker	Day3

5-4. Day3 필수 증빙

① 빈칸 구현 코드

drift_detector.py (빈칸 7, 8)

```
def compute_rmse(recent_predictions):
    if not recent_predictions:
        return 0.0
    se = [(p["actual"] - p["predicted"]) ** 2 for p in recent_predictions]
    return math.sqrt(sum(se) / len(se))

def is_drift(recent_predictions):
    if len(recent_predictions) < WINDOW_SIZE:
        return False
    return compute_rmse(recent_predictions[-WINDOW_SIZE:]) > RMSE_THRESHOLD
```

routers/predict.py batch_test (빈칸 6)

```
for i in range(len(prices) - SEQ_LEN):
    window = prices[i : i + SEQ_LEN]
    pred = model.predict_one([{"close": p, "volume": SIMULATED_VOLUME} for p in window])
    actual = prices[i + SEQ_LEN]
    recent_predictions.append({"predicted": pred, "actual": actual})
recent_predictions[:] = recent_predictions[-21:]
```

빈칸 6에서 actual을 prices[i + SEQ_LEN - 1] 로 잡으면 창문 마지막 날을 "맞힌" 셈이 돼서 RMSE가 비정상적으로 좋아진다. 주식의 질문대로 한 칸 차이가 look-ahead 누수다.

retrain_trigger.py (빈칸 9, 10, 11 + 4-7 수정분)

```

rows = load_rows(latest_upload())[-(SEQ_LEN + 21):]    # 창문 20 + 정답 21 = 41행
result = fine_tune(rows)                               # warm start
if result["promoted"]:
    logger.info(f"[OK] new_rmse={result['rmse']:.2f} - production promoted: HAIC_Predictor v{result['version']}")
    model_loader.invalidate_cache()                    # 4-7: 안 비우면 예전 모델이 계속 응답
    return {"status": "retrain_triggered", "promoted": True, "rmse": result["rmse"]}
return {"status": "retrain_triggered", "promoted": False, "rmse": result["rmse"]}

```

scripts/simulate_drift.py send_batch

```

def send_batch(prices, label):
    resp = requests.post(API_URL, json={"prices": prices.tolist()}, timeout=600)
    resp.raise_for_status()
    result = resp.json()
    print(f"[{label}] drift_check = {result['drift_check']}")
    return result

```

② simulate_drift.py 실행 결과

```

zsh — project — python scripts/simulate_drift.py

$ python scripts/simulate_drift.py
[1] 기준 통계: mean=159.56, std=19.57
[2] 정상 입력 테스트 전송...
[normal] drift_check = {'status': 'ok'}
[3-4] 드리프트 입력 생성·주입...
[drift_injection] drift_check = {'status': 'retrain_triggered', 'promoted': True, 'rmse': 1.4685567832433037}
[5] 결과 확인: requests.log 또는 서버 콘솔에서 [WARN] drift detected 로그를 확인하세요.

```

```

[1] 기준 통계: mean=159.56, std=19.57
[2] 정상 입력 테스트 전송...
[normal] drift_check = {'status': 'ok'}
[3-4] 드리프트 입력 생성·주입...
[drift_injection] drift_check = {'status': 'retrain_triggered', 'promoted': True, 'rmse': 1.4685567832433037}

```

③ aiops.log

```

zsh — project — cat logs/aiops.log

$ cat logs/aiops.log
2026-10-01 02:57:27,127 [WARNING] [WARN] drift detected - triggering retrain
2026-10-01 02:57:27,134 [INFO] [INFO] retrain triggered (window=last_21_days)
2026-10-01 02:57:42,996 [INFO] [OK] new_rmse=1.47 - production promoted: HAIC_Predictor v2

```

```

2026-10-01 02:57:27,127 [WARNING] [WARN] drift detected - triggering retrain
2026-10-01 02:57:27,134 [INFO] [INFO] retrain triggered (window=last_21_days)
2026-10-01 02:57:42,996 [INFO] [OK] new_rmse=1.47 - production promoted: HAIC_Predictor v2

```

감지부터 승격까지 16초. 대시보드 재학습 로그 패널에 같은 세 줄이 떴다. routers/logs.py 가 같은 파일을 웹에서 읽어 주는 거라 터미널과 내용이 같다.

④ 재학습 후 /predict

```
zsh — project — curl /predict (재학습 전 · 후, 같은 입력)

$ curl -s -X POST localhost:8000/predict -d @subnote/requests/predict_ok_20.json # 재학습 전
{"predicted_close":166.26,"model_version":"production-v1"}
$ curl -s -X POST localhost:8000/predict -d @subnote/requests/predict_ok_20.json # 재학습 후 (같은 요청)
{"predicted_close":167.14,"model_version":"production-v2"}
```

```
# 재학습 전 (v1)
{"predicted_close":166.26,"model_version":"production-v1"}
# 재학습 후, 같은 요청 (v2)
{"predicted_close":167.14,"model_version":"production-v2"}
```

4-7 수정 뒤 서버 재시작 없이 바뀐 것을 확인했다.

6. 빈칸 정리 (이 줄이 없으면)

교수님이 "에러 없이 결과만 들어지는 자리에 빈칸을 뒀다"고 하셔서, 채우면서 각 줄이 없으면 어떻게 되는지 같이 적었다.

빈 칸	파일	채운 것	이 줄이 없으면
1	train_baseline_v1.py	<code>model.fit(X_train, y_train_scaled, ...)</code>	test가 학습에 섞이면 RMSE가 실제보다 좋게 나온다
2	model_loader.predict_one	<code>scaler.transform_point(close, volume)</code>	정규화 안 된 원값이 들어가 의미 없는 값
3	위와 같음	<code>scaler.inverse_close(pred_scaled)</code>	0.47 같은 정규화 값이 그대로 응답
4	model_loader.get_model	<code>if _model_cache is None:</code>	매 요청 모델을 새로 읽어 2초씩 지연
5	_load_from_mlflow	<code>HAICScaler.load(SCALER_PATH)</code>	다시 fit하면 가중치 기준과 어긋남
6	predict.batch_test	<code>prices[i:i+SEQ_LEN], prices[i+SEQ_LEN]</code>	한 칸 어긋나면 look-ahead 누수
7	compute_rmse	<code>sqrt(mean((actual-predicted)**2))</code>	\$4 비교가 틀어짐
8	is_drift	<code>len(...) < WINDOW_SIZE → False</code>	표본 1~2건으로 판단해 오탐
9	retrain_trigger	<code>[-(SEQ_LEN + 21):]</code>	21행만 자르면 학습 샘플 1개
10	위와 같음	<code>fine_tune(rows)</code>	41행 scratch 학습은 불안정
11	위와 같음	<code>if result["promoted"]:</code>	탈락한 모델도 성공 로그
추가	retrain_trigger	<code>model_loader.invalidate_cache()</code>	4-7. 로그는 성공인데 서버는 안 바뀜

7. 전체 회고

원래 알던 것. FastAPI로 모델 감싸면 서비스가 된다 정도. MLflow는 이름만. 드리프트는 통계 시간에 분포가 바뀐다는 개념으로만.

이번에 새로 배운 것.

- Day1에서 서버가 떠 있는 것과 예측할 준비가 된 것이 다르다는 걸 Lazy 500 에러로 알았다. 헬스체크가 있다는 것과 헬스체크가 무엇을 확인하는지는 다른 문제다.
- Day2에서 버전이 추상적인 개념이 아니라는 걸 봤다. 내가 몇 번 돌렸는지가 v1, v3로 그대로 남는다. 게이트는 생각보다 단순했다. `if score <= 4.00` 한 줄. 복잡한 장치가 아니라 기준을 숫자로 명확히 정해 두는 게 핵심이었다.
- Day3가 제일 인상 깊었다. 4-7 캐시 문제는 처음엔 빈칸을 잘못 채운 줄 알았는데, 원인은 모듈 사이의 빈틈이었다. 로그를 찍는 모듈과 모델을 들고 있는 모듈이 서로를 몰랐다. 실습가이드가 로그 확인에서 끝내지 않고 재배포 후 `/predict` 응답까지 확인하라고 한 이유를 이해했다.
- 교수님이 "왜 필요하지, 이 위치에서 이 요소 기술이 어떻게 연결되지를 끊임없이 물으면서 가라"고 하셨는데, 빈칸이 정확히 그 자리에 있었다. 문법을 몰라서 못 채우는 빈칸은 없었고, 왜 이 값이어야 하는지를 모르면 틀리게 채워도 돌아가는 빈칸이었다.
- 포트 8000과 8077 같은 사소한 설정이 3일 내내 발목을 잡았다. README, Dockerfile, 스크립트 상수가 같은 값을 보는지 먼저 확인하는 습관이 생겼다.

조별 과제(해아림)에 가져간 것.

HAIC 구조를 태양광 10곳의 다음 날 24시간 발전량 예측으로 옮겼다. 개인 실습에서 겪은 걸 처음부터 넣었다.

- 4-7 캐시 문제는 도메인을 바꿔도 똑같이 생기는 문제라 승격 직후 캐시를 비우고, 응답에 `production-v2` 같은 실제 버전 번호를 넣었다.
- 4-5 경고는 Stage 대신 alias(@champion)로 바꿔 해결했다.
- 재학습을 요청 안에서 동기로 돌리면 그동안 `/predict` 가 멈춘다는 게 부록 8번에 있었다. 백그라운드 스레드로 분리하고 `/jobs/current` 로 상태를 보게 했다. 학습 중에도 기존 버전으로 응답하는 걸 캡처로 남겼다.
- 게이트는 RMSE 고정값이 아니라 "제도 오차 8% 통과율 0.45 이상"으로 바꿨다. 기준선이 0.30이라 그 1.5 배다. 드리프트 임계값도 검증 오차의 1.25배로 유도해서 모델이 바뀌면 자동으로 따라가게 했다.
- HAIC에서는 "오차 크면 재학습" 하나였는데, 실제 발전소 데이터를 넣어 보니 오차가 커지는 이유가 대부분 모델이 아니라 설비 고장이나 날씨였다. 그래서 재학습 전에 원인을 가르는 단계를 하나 끼웠다. 지난 1년 실제 데이터에서 이상은 세 건 다 설비 문제였고, 전부 재학습을 막는 게 맞는 판단이었다. 재학습 루프 자체는 모의 시나리오로 검증했다.
- Lazy/Eager는 조별 코드에서도 다시 켜다. 컨테이너는 Eager, 개발은 Lazy. Docker 빌드도 Mac에서 직접 돌려서 healthy까지 확인했다.

아직 모르는 것. 재학습 검증셋이 6일(4곳 × 6일 = 24 발전소-일)인데 이게 충분한지 확신이 없다. 교수님 Q&A 에도 "fine-tuning 후 게이트 RMSE는 믿을 만한가"가 있었다. 운영이라면 승격 뒤 며칠 새도로 같이 돌려보는 단계가 더 필요할 것 같다. 그리고 황사처럼 지역이 동시에 떨어지는 날씨를 모델 드리프트로 오판할 가능성이 남아 있다.

한 줄로. 모델을 만드는 것과 모델이 계속 맞게 운영하는 것은 다른 일이고, 그 사이를 잇는 게 서빙, 게이트, 감시, 재학습이라는 네 개의 선이었다.