



해아림

태양광 시간별 발전량 예측 B2B 서비스

서빙 → MLOps → AIOps 루프 위에서, 오차의 원인을 가려낸 뒤에만 재학습하는 운영 설계

● 실제 발전소 10 곳 · 3.7 년 실적 · Open-Meteo 기상

● 시나리오 9 개 · 재학습 2 회 · 새 클론에서 재현

예측제도는 " 맞힌 날 " 에만 돈을 준다

하루 전 10 시에 다음 날 24 시간을 제출하고 , 오차율이 작은 날만 정산금을 받는다

4% · 6%

정산 구간 . 2025 년 6 월부터 태양광 4% 이하 4 원 /kWh, 4~6% 3 원 /kWh. 그 전은 6%·8% 였다

D-1 10:00

제출 마감 . 이때 아는 것은 과거 실적과 기상 예보뿐

24h × N 곳

중개사업자 (VPP) 는 매일 발전소 수십 곳의 시간별 예측을 제출

운영자가 매일 부딪히는 네 가지

- 예측이 틀렸는데 원인을 모른다 . 날씨인지 , 설비 고장인지 , 모델이 낡은 것인지 .
- 오차가 커질 때마다 재학습하면 고장 난 발전소를 " 정상 " 으로 학습한다 .
- 점검이 필요한 발전소를 예측 오차만으로는 골라낼 수 없다 .
- 10 시 마감 전에 예측 API 가 멈추거나 느려지면 그날 제출을 못하고 , 제출이 없으면 정산도 없다 .

해아림이 답하는 것

- 내일 24 시간 발전량을 제도 포맷으로 API 한 번에 .
- 오차가 커지면 원인을 날씨 / 설비 / 모델로 자동 분류 .
- 모델 탓일 때만 재학습하고 , 게이트를 통과한 모델만 교체 .
- 설비 탓이면 재학습을 막고 점검 알림 .

제공 기능과 고객이 얻는 것

전력중개사업자 (VPP) 와 발전소 운영자를 위한 B2B API 와 운영 대시보드



다음 날 24 시간 예측 API

72 시간 실적과 24 시간 예보를 보내면 hourly_kwh[24] 와 model_version 을 돌려준다. 제출 자료 준비 시간이 사라진다.



실적 업로드와 사후 대조

컬럼 · 시각 · 중복 · 용량을 검증한 뒤 저장한다. 실적이 들어오면 날짜별 오차율과 PR 을 계산해 누적한다.



원인별 드리프트 대응

21 일 오차율이 임계값을 넘으면 PR · 동시성 · 모양으로 날씨 / 설비 / 오염 / 모델 드리프트를 가른다. 모델일 때만 재학습한다.



설비 점검 알림

그 발전소만 PR 이 0.75 아래면 [ALERT] 를 남기고 재학습을 막는다. 고장을 정상으로 학습하지 않는다.

HAIC 템플릿을 태양광 운영으로 바꾼 표

실습 가이드 7 번 도메인 매핑표 . 예측 대상부터 이해관계자까지 한 칸씩 치환했다

템플릿 개념 (HAIC)	실습 스켈레톤	해아림
예측 대상	다음날 증가 1 개	다음 날 24 시간 발전량 hourly_kwh[24] (제도 제출 포맷)
입력 시퀀스	최근 20 거래일 (close, volume)	최근 72 시간 실적 + 내일 24 시간 기상 예보 + 발전소 id
데이터 공급	대시보드 CSV 업로드	시간별 실적 CSV 업로드 (컬럼 · 시각 · 중복 · 용량 검증) + Open-Meteo 기상
배포 게이트	RMSE ≤ \$4.00	첫 배포 8% 통과율 ≥ 0.45, 이후는 현 운영 모델 이상 (같은 테스트 1 년)
드리프트 신호	변동성 3 배 급변 → RMSE > \$4	21 일 오차율 > 10.36% 이고 , PR · 동시성 · 모양으로 날씨 / 설비 / 오염 / 모델을 가름
재학습	최근 21 거래일 fine-tuning	모델 드리프트일 때만 , 영향 발전소의 최근 30 일로 fine-tuning (마지막 6 일은 검증용)
알림	aiops.log [WARN]	[WARN] 감지 · [ALERT] 설비 점검 · [INFO] 재학습 · [OK] 승격 (대시보드 로그 패널)
이해관계자	투자 분석가 , 운영자	전력중개사업자 (VPP) 운영팀 , 발전소 운영자 , 모델 담당자

운영 목표 : 응답 시간 · 가용성 · 품질

AI 솔루션이 지켜야 할 수치 . Lazy/Eager 는 같은 PC 에서 두 번씩 재서 적었다



응답 시간

/predict 한 건 1 초 이내 . 측정 75 ms (모델 로드 뒤) . 발전소 50
곳을 순서대로 불러도 4 초 안쪽



가용성

재학습은 백그라운드에서 돌고 그동안 /predict 는 기존 버전으로 응답 .
게이트에 걸리면 기존 버전 유지



품질

테스트 1 년 일 오차율 8.29%, 8% 통과율 0.579. 첫 배포 게이트는
통과율 0.45, 이후는 현 운영 모델 이상



입력 검증

길이 · 범위가 틀린 요청은 모델에 달기 전에 422 로 거절 . 어느 필드가 왜
틀렸는지 loc·msg 로 돌려준다

Lazy vs Eager 측정 (mlflow 모드 , CPU, 2 회씩)

모드	서버 시작 → /health 200	시작 직후 model_loade d	첫 /predict	두 번째 /predict
lazy 1 회	3.66 s	false	1,892 ms	76 ms
lazy 2 회	3.44 s	false	1,917 ms	73 ms
eager 1 회	5.04 s	true	342 ms	78 ms
eager 2 회	5.25 s	true	367 ms	75 ms

- Lazy 는 1.8 초 먼저 뜨지만 첫 사용자가 1.9 초를 기다리고 , 모델 파일 문제가 첫 요청 때 드러난다 .
- Eager 는 뜨는 데 1.6 초 더 걸리는 대신 /health 의 model_loaded=true 가 " 받을 준비 됐다 " 는 뜻이 된다 .
- Eager 도 첫 요청이 0.35 초인 것은 TensorFlow 가 첫 호출 때 그래프를 만들기 때문 . 기동 시 예열 호출 한 번이면 없어진다 .

● 선택 : 컨테이너 · 운영은 **Eager (헬스체크가 model_loaded 까지 확인)** , 개발 · 테스트는 **Lazy**

재현 : `python scripts/measure_loading.py → logs/loading_measure.json`

실제 데이터로 만들었다

공개 발전 실적과 Open-Meteo 기상 . 합성 데이터가 아니라 발전소 10 곳의 3.7 년치 시간별 실적이다

10 곳

시간별 계측이 정상인 발전소
(전체 24 곳 중)

3.7 년

2023-01 ~ 2026-08, 321,336
행

7 개 위치

Open-Meteo 관측과 하루 전
예보


1 년

테스트 2025-09 ~ 2026-08,
3,534 발전소 - 일

항목	규칙	이유
예측 단위	이용률 = 발전량 ÷ 설비용량	용량이 다른 발전소 10 곳을 한 모델로 통합
시각 정렬	발전 "N 시 " = N-1~N 시 구간 , 기상은 N 시 직전 1 시간 평균	발전과 기상의 피크가 어긋나지 않게
제외 7 곳	시간별 급변 25~52%, 피크 3~4 시간 지연 , 장기 정지	계측 불량을 모델에 넣지 않는다
설비용량	시간 피크로 추정 (공식값은 plants.csv 에 넣으면 반영)	오차율의 분모이므로 공식값 확인이 필요
학습 / 평가	학습은 관측 기상 , 평가와 서빙은 하루 전 예보도 함께	서빙 조건의 오차를 따로 잰다

시간별 통합 모델 구조


LSTM 이력 인코더 + 내일 기상·태양고도 + 날짜·발전소 임베딩 → 24 시간 이용률 . 파라미터 18,592 개



왜 이 구조인가 · mse 8.98% → 낮 가중 MAE 8.33% → 발전소 임베딩 7.99% (실험). 학습 길이 · 피쳐 추가 · 앙상블은 효과 없음 . 제도 오차율은 낮만 세므로 손실도 낮에 집중 .

기준선 대비 오차 절반

테스트 1년 · 발전소 10곳 · 3,534 발전소-일 · 일 오차율 = 용량 대비 시간 오차의 낮 시간 평균



8.29%

운영 모델 (관측 기상)

0.58

8% 통과율 (기준선 0.30)

9.85%

하루 전 예보 입력 (서빙)

0.49



서빙 조건 통과율

예보 입력 격차 1.5%p

드리프트가 아니라 입력 품질의 몫이다. 예보 소스 개선, 최신 런 사용, 예보로 학습하는 것이 다음 과제. 재학습으로는 줄지 않는다.

계절 변동은 모델이 이미 아는 것

장마철 (7 월) 통과율 0.45 는 드리프트가 아니라 모델 성능의 한계다 . 가을 (11 월) 은 0.71



장마철 오차가 큰 이유 : 구름이 " 몇 시에 걷히느냐 " 를 시간 단위로 맞춰야 하고 , 평가에 남는 시간은 가장 변동이 큰 시간뿐이다 . 보수적 예측 손실과 예보로 학습이 다음 과제 .

지표 하나로 통일하고 , 게이트가 배포를 막는다

학습 손실 , 배포 게이트 , 드리프트 임계값이 모두 같은 제도 오차율에서 나온다

제도 오차율 (data/metrics.py)

시간 오차율 = $| \text{예측} - \text{실제} | \div \text{설비용량} \times 100$

발전량이 용량의 10% 이상인 시간만

일 오차율 = 시간 오차율의 평균 $\rightarrow$ 8% 이하를 내부 품질 기준으로
(제도 정산 구간은 4%·6%. 8%는 모델 통과율용 기준)

PR = $\sum \text{실제} \div \sum (\text{관측 기상으로 낸 기대치})$

1.0 = 설비가 모델이 아는 정상 상태

첫 배포

8% 통과율 ≥ 0.45

기준선 0.30 의 1.5 배 . 실제 0.579 로 통과

이후 배포

현 운영 모델 이상

같은 테스트 1 년에서 챔피언 / 챌린저 비교

재학습

남겨 둔 6 일에서 현 모델보다 오차가 낮을 때만

30 일 중 앞 24 일로 학습 , 뒤 6 일은 손대지 않고 두 모델을 같은 날짜로 비교 . 기후 B 에서는 4 곳 $\times$ 6 일 = 24 발전소 - 일 , 16.32% $\rightarrow$ 8.39%

드리프트 임계값은 검증 오차에서 유도한다

- 임계값 = $\max(8\%, \text{검증 오차 } 8.29\% \times 1.25) = 10.36\%$. 고정 8% 를 쓰면 평상시 (8.3%) 가 매일 드리프트가 된다 .
- 최근 21 일 일 오차율 평균이 임계값을 넘을 때만 원인 분류로 넘어간다 . 7 일 미만이면 보류 .
- 서버 조건외 오차와 예보 괴리 (관측 - 예보 일사량 차이) 를 함께 기록해 " 예보가 빗나간 날 " 을 설명한다 .

드리프트는 모양으로 알아본다

성능비 PR 이 시간에 따라 그리는 모양. 같은 "오차 상승" 이라도 모양이 다르면 원인과 대응이 다르다



급락 (sudden)

하루 만에 계단형으로 떨어져 유지

예 : 삼천포 2 12/16

● 설비 이상 → **[ALERT]**




점진 (incremental)

몇 주 ~ 몇 달에 걸쳐 한 방향으로

예 : 영흥 #5 3~8 월

● 설비 · 오염 → 점검 권고




복귀 (recurring)

떨어졌다가 원래대로 돌아옴

예 : 광양항 11 월 , 삼천포 2 1/9

● 설비였다는 사후 확인




날씨 (no shift)

위아래로 흔들리지만 평균은 1.0

예 : 장마철

● 정상 → 재학습 없음




동시 변화 (concurrent)

여러 발전소가 같은 시기에 같은 방향

예 : 기후 B 폭염화 (모의)

● 모델 드리프트 → 재학습



위로 틀림 (PR > 1.15)


실제가 기대보다 계속 많음

예 : 광양항 복구 후

● 모델 기준 오류 → 재학습

오차가 커졌다는 것과 모델이 틀렸다는 것은 다르다


발전소가 기대보다 덜 만들 이유는 많지만 더 만들 이유는 없다. 다섯 단계로 원인을 가른다



원인	PR (실제 ÷ 기대치)	범위	모양	대응
날씨 · 예보 빗나감	≈ 1.0	한 지역	며칠	알림만
설비 고장 · 정지	0.75 아래로 급락	한 곳	계단형	[ALERT], 재학습 차단
오염 · 노후 · 그늘	0.75~0.92, 단조 하락	한 곳	몇 주 ~ 몇 달	청소 · 점검 권고
모델 드리프트	여러 곳 같은 방향, 또는 1.15 초과	절반 이상 동시	동시	fine-tune → 게이트 → 재배포

AIops 파이프라인 8 단계와 운영 안전장치

대시보드는 aiops.log 의 [WARN] → [INFO] → [OK] 를 읽어 단계를 켜다 . 모델 드리프트일 때만 5 단계로 넘어간다



재학습은 백그라운드 작업



/jobs/current 로 상태를 본다 . 학습 중에도 /predict 는 기존 버전으로 응답하고 , 진행 중이면 새 요청은 같은 작업으로 합친다 .

MLflow alias @champion



승격은 alias 이동이다 . 게이트에 걸리면 기존 버전을 유지하고 , 학습이 실패해도 서빙은 그대로다 .

재학습 데이터 선별



같은 시기에 PR 이 0.75 아래인 발전소는 동시성에 묶여도 제외한다 . 영흥 #5 를 섞으면 새 모델 오차가 10.41% 에서 10.95% 로 나빠졌다 .

검증과 테스트



업로드는 컬럼 · 시각 · 중복 · 미등록 발전소 · 용량 범위를 검사해 거부한다 . 계약 테스트 14 개 . 새 클론에서 전체 재현 .

시나리오 9 개 : 날씨 3 · 설비 4 · 모델 드리프트 2


실제 실적 구간을 그대로 또는 변형해 투입했다. 재학습은 두 번만 걸렸고 둘 다 게이트를 통과했다

구분	시나리오	데이터	일 오차율	PR	판정 → 대응
날씨	정상	삼천포 2 2026-08-11~31	7.17%	0.98	정상
날씨	장마철	삼천포 2 2026-06-20~07-10	9.19%	1.05	정상 (모델이 아는 계절)
날씨	기후 A 우기 패턴만	6 곳 장마철 실적 그대로	6.9~9.2%	0.98~1.11	정상 (입력 분포만 변화)
설비	합성 고장	삼천포 2, 8 일째부터 $\times 0.5$	16.29%	0.46	설비 이상 → [ALERT]
설비	광양항 (실제)	2025-10-05~25, 10/6~11 정지	23.46%	0.44	설비 이상 → [ALERT]
설비	삼천포 2 (실제)	2025-12-05~25, 12/16 급락	15.81%	0.47	설비 이상 → [ALERT]
설비	영흥 #5 (실제)	2026-08-11~31, 3 월부터 점진 하락	11.69%	0.68	설비 이상 → [ALERT]
모델	기후 B 폭염화 (모의)	6 곳 2026-07-11~31, 28°C 초과 1°C 당 - 5%	10.9~15.0%	0.70~0.75	모델 드리프트 → fine-tune 8.39% → v2
모델	전 발전소 변화 (루프 검증)	경남 3 곳 $\times 1.25$	12.2~14.2%	1.19~1.22	모델 드리프트 → fine-tune → v3

● 같은 20% 손실을 장마 창에 넣으면 오차 8.5~9.2%로 임계값 미달. 제도 오차는 용량 대비 절대값이라 흐린 날의 비례 손실은 작게 잡힌다.

실제 사례 ① 광양항 : 정지했다가 돌아왔다

2025 년 9~10 월 PR 0.3~0.4 지속 , 10/6~11 완전 정지 , 11 월 초 복구 . 급락과 복귀 모양



판정

오차 23.5%, PR 0.44 → 설비 이상 .
[ALERT] 만 남기고 재학습 차단

근거


같은 기간 다른 9 곳 PR 0.85~1.10. 한
곳만 떨어졌다

배운 것

창 시작 전에 이미 떨어진 경우도 PR <
0.75 면 설비로 본다 (규칙 보강)

실제 사례 ② 삼천포 2 호기 : 하루 만에 절반

2025-12-16 PR 0.96 → 0.46, 3 주 유지 후 1/9 복구 . 전형적인 계단형 급락



판정

오차 15.8%, PR 0.47 → 설비 이상 .
[ALERT]

근거

같은 부지 삼천포 3 는 0.84 유지 . 하루
만에 떨어지고 하루 만에 돌아온 모양은 점
검 · 부분 정지


배운 것

합성 고장 시나리오 (×0.5) 와 같은 모양이고
감지기도 같은 판정을 냈다

실제 사례 ③ 영흥 #5: 여섯 달에 걸쳐 서서히

2026 년 3 월 0.96 → 8 월 0.64. 전 시간대 균일 손실 , 피크 이용률 0.84 → 0.78

영흥#5 · 6개월에 걸친 점진 하락



판정

오차 11.7%, PR 0.68 → 설비 이상 . 60 일 이상 기록이면 오염으로 재분류

근거

같은 부지 영흥 2 호기는 1.0 근처 . 날씨나 기상 데이터 문제가 아니다


추정

스트링 · 인버터 일부 탈락 또는 심한 오염 . 운영 이력 대조 필요

지난 1년, 열 곳이 동시에 틀린 달은 없었다

월별 PR 중앙값 0.93~1.03. 재학습이 필요한 모델 드리프트는 실제 데이터에 없었다

발전소 10곳 월별 PR 중앙값 · 동시에 틀린 달이 없다



해석

이상은 전부 발전소 단위였고 감지기는 세 건 모두 재학습을 막았다

예외

광양항 복구 후 PR 1.15~1.22 (2026-04~07). 위로 틀린 유일한 구간

의미

재학습은 "데이터를 더 넣는 일"이 아니라
"잘못 배운 것을 바로잡는 일"

모델 드리프트 : 여러 곳이 같이 틀리거나, 위로 틀리거나

재학습이 정답인 경우는 " 같은 입력에서 발전 패턴이 바뀌었는데 메타데이터 수정으로는 못 고치는 " 경우다


● model_drift · 4곳 동시 → 재학습 → v2 승격 (모의)

삼천포 2호기 2026-07-11 ~ 2026-07-31 · 경상대 2026-07-11 ~ 2026-07-31 · 구미 2026-07-11 ~ 2026-07-31

같은 6곳의 장마 직후 폭염 3주(7/11~31)에 관측 기온이 28°C를 넘는 시간마다 1°C당 5% 손실을 넣었습니다.
더운 경남 4곳은 오차 10.9~15.0%, PR 0.70~0.75로 임계값을 넘고 덜 더운 경북 2곳은 8.4~8.6%로 이내입니다.
다. 동시성 0.67로 모델 드리프트 판정, 4곳 최근 30일로 fine-tuning한 모델이 8.39%를 내 v2로 승격했습니다.
같은 손실을 장마 창에 넣으면 오차 8.5~9.2%로 임계값에 못 미칩니다. 제도 오차율은 용량 대비 절대 오차라 흐린 날의 비례 손실은 작게 잡히기 때문입니다.

발전소	일 오차율 평균	8% 통과율	PR 평균	임계값
삼천포 2호기	12.92%	0.19	0.737	10.36%
경상대	15.03%	0.095	0.735	10.36%
구미	8.41%	0.429	0.899	10.36%

성능비 PR (실제 ÷ 기상 기대치)



● 발전소는 덜 만들 이유는 많지만 더 만들 이유는 없다 → 위로 틀리면 모델을 의심한다

같은 20% 손실을 장마 창에 넣어도 임계값에 못 미친다 → 기후 시나리오는 맑은 폭염 창에 두었다

기후 B · 폭염화 (모의)


28°C 초과 1°C 당 - 5% 손실을 3 주 넣었다.
더운 경남 4 곳만 넘고 경북 2 곳은 이내 → 동시성 0.67 → 재학습 → 새 오차 8.39%로 v2 승격.
우기 패턴만 바뀐 A는 재학습하지 않는다.

광양항 복구 후 · 실제

넉 달 동안 실제가 기대보다 20% 많다. 구름·먼지·고장은 발전을 더 만들지 못하므로 틀린 쪽은 모델의 기준. PR > 1.15 규칙은 한 곳이어도 재학습으로 보낸다.

시스템 구성도 : 업로드에서 재배포까지 한 바퀴

위 줄은 만들어 내보내는 길 (Day1·Day2), 아래 줄은 지켜보고 고치는 길 (Day3). 모듈 이름은 저장소의 파일 이름 그대로다



실선 상자 = 코드 모듈 · 점선 상자 = 파일 · 저장소 · 화살표 = 호출과 읽기 · 쓰기 · 빨간 고리 = 모델 드리프트일 때만 도는 길

운영 API 계약

21

FastAPI 와 Pydantic 검증 . Swagger /docs 는 CDN 없이도 열린다 . 틀린 입력은 모델에 닿기 전에 422 로 돌려보낸다

Method / URL	입력	결과	용도
POST /predict	plant_id, date, history_kwh[72], forecast[24]{ghi, cloud_cover, temperature}	200 hourly_kwh[24], day_total_kwh, model_version · 422 길이 · 범위 위반	다음 날 제출 자료
POST /data/upload	CSV 또는 .gz (plant_id, time, generation_kwh)	200 rows, rejected_rows · 400 형식 · 중복 · 용량 위반	실적 갱신
GET /data/status · /data/window	plant_id, start, n_days, scale, heat_loss	발전소별 기간 / 시뮬레이션용 구간	운영 확인 · 시나리오
POST /predict/batch-test	records(72h+24h 이상), persist, check	days[], summary, drift_check{status, cause, retrain}	사후 평가 · 드리프트 판정
GET /jobs/current	-	idle / queued / running / completed / failed	재학습 상태
GET /health · GET /logs/aiops.log	-	status, model_loaded, model_version, loading_mode, training / 로그 본문	서비스 상태 · 증빙

200 정상 응답

```
POST /predict {"plant_id":"samcheonpo_2","date":"2026-08-30",
  "history_kwh":[0,0,...,559.68,...],"forecast":
[{"ghi":0,"cloud_cover":20,"temperature":23.1},...]}
→ 200 {"hourly_kwh":[0,0,0,0,0,0,0.8,107.6,211.1,334.4,432,519,534.4,...,0],
  "day_total_kwh":3649.7,"model_version":"production-v1"}
GET /health → {"status":"ok","model_loaded":true,"model_version":"production-
v1","loading_mode":"eager","training":"idle"}
```

422 검증 오류 (history_kwh 71 개를 보냈을 때)

```
POST /predict {... "history_kwh":[71개] ...}
→ 422 {"detail":[{"type":"too_short","loc":["body","history_kwh"],
  "msg":"List should have at least 72 items after validation, not 71"}]}
같은 식으로 ghi < 0, cloud_cover > 100, temperature 범위 밖, forecast 23개도
422.
업로드는 time 형식 · 중복 · 미등록 발전소 · 용량 초과를 400 으로 돌려보낸다 .
```

실행 증빙 ① 대시보드 : 설비는 멈추고 , 모델 드리프트는 끝까지

버튼 한 번으로 실적 구간 투입 → 판정 → 파이프라인 8 단계 표시 (2026-10-01 실제 실행 캡처)

정상 (삼천포2 최근 21일)

장마철 (2026-06-20~)

설비 고장 (8일째부터 ×0.5)

전 발전소 변화 (3곳 ×1.25)

실제 데이터에서 찾은 사례 (주입 없음)

광양항 2025-10 (PR 0.3 지속)

삼천포2 2025-12 (급락)

영흥#5 2026-08 (점진 하락)

기후 A: 우기 패턴만 (6곳, 2026-06-20~)

기후 B: 폭염화 관계 변화 (6곳, 28°C↑ 1°C당 -5%)

● 설비 이상 의심 (PR < 0.75) → 운영자 알림, 재학습 금지

samcheonpo_2 · 2026-08-11 ~ 2026-08-31 · 일 오차를 평균 16.29% · 8% 통과율 0.316 · PR 0.66 · D-1 예보 입력 오차 14.58% · 예보 과리 9.71% · 창(21일) 오차 16.29% / 일계값 10.36%

드리프트 감지 기반 재학습 파이프라인

위에서 배치를 보내면, 그 요청이 실제로 거쳐간 단계를 아래에 표시합니다 (자동 스케줄러는 없고, 수동 트리거 방식입니다).

데이터 수집

데이터 모니터

드리프트 감지

원인 분류

재학습 트리거

모델 학습

모델 등록

배포

요청 수신

예측 기록 누적

21일 오차를 vs 임계값

PR · 발전소 동시성

model_drift 일 때만

fine-tuning

MLflow Registry

Production 승격

완료

완료

감지됨

감지됨

대기 중

대기 중

대기 중

● 설비 고장 ×0.5 → 설비 이상 · 알림 , 재학습 트리거 대기

오차 16.29%, PR 0.66. 파이프라인은 4 단계 (원인 분류) 에서 멈추고 재학습 트리거는 " 대기 중 ". aiops.log 에는 [WARN] 과 [ALERT] 두 줄 .

정상 (삼천포2 최근 21일)

장마철 (2026-06-20~)

설비 고장 (8일째부터 ×0.5)

전 발전소 변화 (3곳 ×1.25)

실제 데이터에서 찾은 사례 (주입 없음)

광양항 2025-10 (PR 0.3 지속)

삼천포2 2025-12 (급락)

영흥#5 2026-08 (점진 하락)

기후 A: 우기 패턴만 (6곳, 2026-06-20~)

기후 B: 폭염화 관계 변화 (6곳, 28°C↑ 1°C당 -5%)

● 모델 드리프트 (여러 발전소 동시) → 재학습 · 재학습 완료, 새 버전 승격 (new_error=8.39%)

yecheon_1 · 2026-07-11 ~ 2026-07-31 · 일 오차를 평균 8.63% · 8% 통과율 0.619 · PR 0.866 · D-1 예보 입력 오차 7.37% · 예보 과리 9.48% · 창(21일) 오차 12.92% / 일계값 10.36%

드리프트 감지 기반 재학습 파이프라인

위에서 배치를 보내면, 그 요청이 실제로 거쳐간 단계를 아래에 표시합니다 (자동 스케줄러는 없고, 수동 트리거 방식입니다).

데이터 수집

데이터 모니터

드리프트 감지

원인 분류

재학습 트리거

모델 학습

모델 등록

배포

요청 수신

예측 기록 누적

21일 오차를 vs 임계값

PR · 발전소 동시성

model_drift 일 때만

fine-tuning

MLflow Registry

Production 승격

완료

완료

감지됨

감지됨

완료

완료

완료

● 기후 B → 모델 드리프트 · 재학습 → 게이트 → v2 승격 , 8 단계 완료

new_error 8.39% 로 새 버전 승격 , 8 단계 모두 " 완료 ". 상단 배지는 학습 중 " 재학습 running " 으로 바뀌었다가 끝나면 모델 버전이 v2 로 바뀐다 .

실행 증빙 ② 학습 중에도 응답하고, 로그는 순서대로 남는다

/health 가 재학습 running 을 보여주는 동안 /predict 는 production-v1 로 응답한다



```
17:00:50 [WARN] drift detected (cause=equipment, plant=samcheonpo_2, err=16.29% (thr 10.36%), pr_recent=0.464, pr_before=0.766, fleet_share=0.0)
17:00:50 [ALERT] equipment anomaly suspected at samcheonpo_2 (PR 0.464) - retrain blocked, operator notified
17:00:57 [WARN] drift detected (cause=equipment, plant=yeongheung5_1, err=11.69% (thr 10.36%), pr_recent=0.678, pr_before=0.653, fleet_share=0.5)
17:00:57 [ALERT] equipment anomaly suspected at yeongheung5_1 (PR 0.678) - retrain blocked, operator notified
17:01:24 [WARN] drift detected - triggering retrain (cause=model_drift, plant=samcheonpo_2, err=12.92% (thr 10.36%), pr_recent=0.712, pr_before=0.75, fleet_share=0.67)
17:01:24 [INFO] retrain triggered (window=last_30_days, plants=doosan_1,gyeongsang_1,samcheonpo_2,samcheonpo_3, job=345ed0baa11d)
17:01:41 [OK] new_error=8.39% - production promoted: Haeirim Hourly v2
17:01:56 [WARN] drift detected (cause=equipment, plant=samcheonpo_2, err=11.59% (thr 10.36%), pr_recent=0.574, pr_before=0.935, fleet_share=0.5)
17:01:56 [ALERT] equipment anomaly suspected at samcheonpo_2 (PR 0.574) - retrain blocked, operator notified
```

해아림 v2 - 태양광 시간별 발전량 예측 Serving & AIOps 0.1.0 OAS 3.1

/openapi.json

default

POST	/predict	Predict	^
POST	/predict/batch-test	Batch Test	^
GET	/jobs/current	Current Job	^
GET	/predict/drift-state	Drift State	^
GET	/health	Health	^
POST	/data/upload	Upload	^
GET	/data/status	Status	^
GET	/data/window	Window	^
GET	/logs	List Logs	^
GET	/logs/{filename}	Read Log	^

/predict 응답의 model_version

재학습 전 "production-v1"
 학습 중 /health {"training": "running"} · 응답은 여전히 v1
 승격 후 "production-v2"

실행 증빙 ③ 같은 요청 , 재학습 전과 후

Swagger /predict Try it out. 같은 삼천포 2 입력에 production-v1 과 production-v2 가 다르게 답한다

Server response	
Code	Details
200	Response body <pre>{ "plant_id": "samcheonpo_2", "date": "2026-08-30", "hourly_kwh": [0, 0, 0, 0, 0, 0, 0, 0.8, 107.6, 211.1, 334.4, 432, 519, 534.4, 461.1, 407.3, 335.6, 212, 94.3, 0.1, 0, 0, 0, 0, 0], "day_total_kwh": 3649.7, "model_version": "production-v1" }</pre> Response headers <pre>content-length: 234 content-type: application/json date: Fri, 02 Oct 2026 01:45:05 GMT server: uvicorn</pre>

Server response	
Code	Details
200	Response body <pre>{ "plant_id": "samcheonpo_2", "date": "2026-08-30", "hourly_kwh": [0, 0, 0, 0, 0, 0, 0, 1.1, 66.8, 159.7, 234.4, 305.4, 379, 402.7, 317.3, 286.8, 289.2, 178.8, 87.4, 0.1, 0, 0, 0, 0, 0], "day_total_kwh": 2708.7, "model_version": "production-v2" }</pre> Response headers <pre>content-length: 233 content-type: application/json date: Fri, 02 Oct 2026 01:45:23 GMT server: uvicorn</pre>

● 재학습 전 · "model_version": "production-v1" · 3,649.7 kWh

● 재학습 후 · "model_version": "production-v2" · 2,708.7 kWh

폭염 손실을 배운 v2 가 같은 날 발전량을 낮게 본다 . 승격 직후 /health 는 model_loaded=false(캐시 비움) 였다가 첫 요청에서 v2 를 올린다 .

실행 증빙 ④ 컨테이너에서도 같은 화면

docker compose up --build 한 번으로 실적 시드 → 모델 등록 → 계약 테스트 → 서빙까지 이미지 안에서 끝난다

Mac 에서 캡처해 넣는 자리

shots/docker_01.png

`docker compose -f serving_app/docker-compose.yml
up --build`

빌드 로그 : [GATE PASSED] · 14 passed · Uvicorn
running on 0.0.0.0:8010

Mac 에서 캡처해 넣는 자리

shots/docker_02.png

`docker ps`

STATUS = healthy (HEALTHCHECK 가 /health 의
model_loaded=true 까지 확인)

Mac 에서 캡처해 넣는 자리

shots/docker_03.png

<http://localhost:8010/docs> (컨테이너)

/predict Try it out → 200, model_version production-
v1

Dockerfile 줄	하는 일
FROM python:3.11-slim · COPY requirements.txt · RUN pip install	로컬과 같은 Python, 의존성 레이어는 소스보다 먼저 (캐시)
RUN cp sample → data/uploads && train_and_register.py --register-local && pytest	이미지 빌드 시점에 시드 · 게이트 · 등록 · 테스트까지 끝내 자기 완결
ENV MODEL_SOURCE=mflow LOADING_MODE=eager · HEALTHCHECK · CMD uvicorn :8010	뜨자마자 모델이 올라와 있고 , healthy 가 곧 " 받을 준비 됨 "

한계와 다음 단계

모의임을 밝히고 , 운영에 넣기 전에 확인할 것을 적는다

	이력 창 마감 시각	지금은 D-1 24:00 까지 쓴다 . 제출이 D-1 10 시이므로 09:00 마감으로 바꾸면 조건이 정직해지고 오차는 조금 오른다 .
	감시 오차의 기준	판정은 관측 기상 예측 오차 (8.29%) 기준이다 . 서빙 조건 (9.85%) 으로 옮기면 임계값도 다시 잡아야 한다 .
	설비용량 · 좌표	plants.csv 의 용량은 시간 피크 추정값이다 . 공식 용량 · 좌표와 세 발전소의 운영 이력을 대조해야 사례가 확정된다 .
	장마철 통과율 0.45	드리프트가 아니라 모델 성능의 한계다 . 보수적 예측 손실과 예보로 학습하는 것이 다음 과제다 .
	시나리오 확장	출력제어 (제도 변화 → 재학습) 와 황사 (지역 동시지만 일시적 → 재학습 금지) 로 동시성 규칙의 경계를 보강한다 .

역할 분담과 실행 안내

저장소 github.com/leemingi0906/model-serving · 팀 공유 zip [Haearim_v2_team.zip](#) · 3~5 분이면 같은 화면이 뜬다

담당	구현한 것	완료 증거
A 데이터 · 기획	시각 정렬, 이용률, 레지스트리, 업로드 검증, 기획안	정합성 검토, 7 곳 제외 근거, 계약 테스트
B 모델 · MLOps	LSTM 구조, 낮 가중 손실, 게이트, MLflow alias	게이트 통과 8.29% / 0.579, 모델 실험 2 라운드
C 서빙 · 배포	스키마, /predict, 모델 스냅샷 교체, 오프라인 Swagger	24 시간 응답, model_version v1 → v2, 학습 중 응답
D AIOps · 검증	원인 분류, 재학습 트리거, 백그라운드 작업, 시나리오 9 개, 대시보드	aiops.log, 새 클론 재현 로그

팀원 PC 에서 (TEAM_GUIDE.md)

```

pip install -r requirements.txt
bash scripts/quick_start.sh      # 업로드 → 동봉 모델 등록 → 서버
python scripts/simulate_drift.py # 시나리오 9 개
python -m pytest -q              # 계약 테스트 14 개
python scripts/measure_loading.py # Lazy/Eager 측정표
docker compose -f serving_app/docker-compose.yml up --build
http://localhost:8010 · /docs

```

발표의 한 줄

"오차가 커져도 날씨면 둔다, 한 곳이면 고친다, 모두면 다시 배운다."

재학습은 데이터를 더 넣는 일이 아니라 모델이 잘못 알고 있는 것을 바로잡는 일이다. 그래서 원인을 먼저 가린다.